



UNIVERSIDADE DE SÃO PAULO  
ESCOLA DE ENGENHARIA DE SÃO CARLOS

# **SEL632 - LINGUAGENS DE DESCRIÇÃO DE HARDWARE**

## **Entrega 01**

Leonardo J. R. Baptistella - N°USP 10821172  
Murilo Henrique Pasini Trevisan - N°USP 9796078

São Carlos

2022

# 1 NEURÔNIO ARTIFICIAL

A partir da estrutura e funcionamento do neurônio biológico, pesquisadores tentaram simular este sistema em computador. O modelo mais bem aceito foi proposto por Warren McCulloch e Walter Pitts em 1943, o qual implementa de maneira simplificada os componentes e o funcionamento de um neurônio biológico. Em termos simples, um neurônio matemático de uma rede neural artificial é um componente que calcula a soma ponderada de vários **inputs**, aplica uma função e passa o resultado adiante.(O..., [Acessado em maio 2022](#))

Neste modelo de neurônio matemático, os impulsos elétricos provenientes de outros neurônios são representados pelos chamados sinais de entrada (representado pela letra  $x$  no diagrama 3 abaixo, que nada mais são do que os dados que alimentam seu modelo de rede neural artificial). Dentre os vários estímulos recebidos, alguns excitarão mais e outros menos o neurônio receptor e essa medida de quão excitatório é o estímulo é representada no modelo de Warren McCulloch e Walter Pitts através dos pesos sinápticos. Quanto maior o valor do peso, mais excitatório é o estímulo. Os pesos sinápticos são representados por  $w_{kn}$  no diagrama 3, onde  $k$  representa o índice do neurônio em questão e  $n$  se refere ao terminal de entrada da sinapse a qual o peso sináptico se refere.(O..., [Acessado em maio 2022](#))

A soma ou corpo da célula é representada por uma composição de dois módulos, o primeiro é uma junção aditiva, somatório dos estímulos (sinais de entrada) multiplicado pelo seu fator excitatório (pesos sinápticos), e posteriormente uma função de ativação, que definirá com base nas entradas e pesos sinápticos, qual será a saída do neurônio. O axônio é aqui representado pela saída ( $y_k$ ) obtida pela aplicação da função de ativação. Assim como no modelo biológico, o estímulo pode ser excitatório ou inibitório, representado pelo peso sináptico positivo ou negativo respectivamente.(O..., [Acessado em maio 2022](#))




Figura 1 – Representação Simplificada do Neurônio Matemático  
 Fonte: (, [Acessado em maio 2022b](#))

O modelo proposto possui uma natureza binária. Tanto os sinais de entrada quanto a saída, são valores binários. McCulloch acreditava que o funcionamento do sistema nervoso central possuía um caráter binário, ou seja, um neurônio influencia ou não outro neurônio, mas posteriormente mostrou-se que não era dessa forma.(O... , [Acessado em maio 2022](#))

Os dendritos e axônios são representados matematicamente apenas pelas sinapses, e a intensidade da ligação é representada por uma grandeza denominada peso sináptico, simbolizada pela letra  $w$ . Quando as entradas,  $x$ , são apresentadas ao neurônio, elas são multiplicadas pelos pesos sinápticos correspondentes, gerando as entradas ponderadas, ou seja,  $x_1$  que multiplica  $w_1$  e assim por diante. Isso descreve uma das bases matemáticas do funcionamento de uma rede neural artificial, a multiplicação de matrizes.(O... , [Acessado em maio 2022](#))

$$\mathbf{Xw} = \mathbf{y}$$

$$\begin{bmatrix} 1 & x_{11} & \dots & x_{1d} \\ 1 & x_{21} & \dots & x_{2d} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & \dots & x_{nd} \end{bmatrix} \times \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_d \end{bmatrix} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{bmatrix}$$

Figura 2 – Multiplicação de Matrizes Entre Sinais de Entrada  $x$  e Pesos Sinápticos  $w$   
 Fonte: (, [Acessado em maio 2022a](#))

O neurônio, então, totaliza todos os produtos gerando um único resultado. A esta função se denomina função de combinação. Este valor é então apresentado a uma função de ativação ou função de transferência, que tem, dentre outras, a finalidade de evitar o acréscimo progressivo dos valores de saída ao longo das camadas da rede, visto que tais funções possuem valores máximos e mínimos contidos em intervalos determinados. O uso de funções de transferência não-lineares torna a rede neural uma ferramenta poderosa.

Sabe-se que uma rede perceptron de duas camadas com função de transferência não-linear como a função sigmóide, é denominada de aproximador universal.(O..., Acessado em maio 2022)

Dessa forma, o neurônio dispara quando a soma dos impulsos que ele recebe ultrapassa o seu limiar de excitação, chamado de threshold. O corpo do neurônio, por sua vez, é emulado por um mecanismo simples que faz a soma dos valores  $x_i$  e  $w_i$  recebidos pelo neurônio (soma ponderada) e decide se o neurônio deve ou não disparar (saída igual a 1 ou a 0) comparando a soma obtida ao limiar ou threshold do neurônio. A ativação do neurônio é obtida através da aplicação de uma “função de ativação”, que ativa a saída ou não, dependendo do valor da soma ponderada das suas entradas.(DEEP LEARNING BOOK, 2018)

Nota-se que este modelo matemático simplificado de um neurônio é estático, ou seja, não considera a dinâmica do neurônio natural. No neurônio biológico, os sinais são enviados em pulsos e alguns componentes dos neurônios biológicos, a exemplo do axônio, funcionam como filtros de frequência.(O..., Acessado em maio 2022)

Portanto, num neurônio artificial, temos o seguinte esquema:




Figura 3 – Representação do Neurônio Artificial

Fonte: (, Acessado em maio 2022c)

Da forma que é possível encontrar os seguintes componentes:

- Os sinais de entrada ( $x_1, \dots, x_n$ ) são os sinais externos normalmente normalizados para incrementar a eficiência computacional dos algoritmos de aprendizagem.

- Os pesos sinápticos ( $w_1, \dots, w_n$ ) são valores para ponderar os sinais de cada entrada da rede.
- O combinador linear ( $\Sigma$ ) é responsável por agregar todos os sinais de entrada que foram ponderados pelos respectivos pesos sinápticos a fim de produzir um potencial de ativação.
- O limiar de ativação ( $\theta$ ) especifica qual será o patamar apropriado para que o resultado produzido pelo combinador linear possa gerar um valor de disparo de ativação
- O potencial de ativação ( $u$ ) é o resultado obtido pela diferença do valor produzido entre o combinador linear e o limiar de ativação. Se o valor for positivo, então o neurônio produz um potencial excitatório, caso contrário, o potencial será inibitório.
- A função de ativação ( $g$ ) tem o objetivo de limitar a saída de um neurônio em um intervalo valores.
- O sinal de saída ( $y$ ) é o valor final de saída podendo ser usado como entrada de outros neurônios que estão sequencialmente interligados.

## 2 REPRESENTAÇÃO EM PONTO FIXO: Q-FORMAT

A representação de números reais em um sistema digital pode ser com ponto fixo, ou com ponto flutuante. Sistemas com ponto flutuante permitem variação da quantidade de dígitos antes e após o ponto. A representação é feita no seguinte formato ([FRANCO, 2006](#)):

$$F(\beta, t, m, M) = \pm 0.d_1 d_2 \dots D - t \cdot \beta^e, d_1 \neq 0, m \leq e \leq M$$

Percebe-se uma extensão de possíveis valores que o expoente  $e$  pode assumir, o que permite a representação de ordens de grandeza muito distintas com um mesmo tipo de dado. Representações em ponto fixo, por sua vez, possuem resolução fixa. Um equacionamento possível é ([FRANCO, 2006](#)):

$$x = \pm \sum_{i=k}^n x_i \cdot B^{-i}$$

Q-format é um formato de representação de ponto fixo caracterizada pela especificação da quantidade de bits, tanto para bits destinados a dígitos inteiros quanto para bits destinados a dígitos fracionários (Q. . . , 2021). Se o formato for Q3.2, por exemplo, a parte inteira vai de 0 a 7, e a parte fracionária de 0 a 3. Aqui, introduz-se a notação de Q-format ([OBERSTAR, 2007](#)):

$$Q[QI] \cdot [QF] \tag{2.1}$$

Em que QI indica o número de bits para inteiros e QF o número de bits para fracionários. Essa forma de representação implica em uma ambiguidade envolvendo o sinal, que pode, ou não, ter seu bit incluído em QI. No caso de dados do tipo unsigned, tanto QI quanto QF têm range descrito em:

$$0 \leq \alpha \leq (2^{Q^*} - 1)$$

Já no caso de serem representados valores positivos e negativos, com valores negativos em complemento de 2, o range de QI passa a:

$$(-2^{QI-1}) \leq \alpha \leq (2^{QI} - 1)$$

É interessante notar que a resolução  $\epsilon$  dos dados é determinada pela porção QF:

$$\epsilon = 2^{-QF}$$

Dessa forma, é possível descrever uma representação em Q-format de modo mais completo, levando em consideração o range e resolução totais - o que é de extrema importância para que se determine um bom formato para as necessidades da implementação a ser realizada. O range total para dados unsigned e signed, bem como a resolução, são descritos, respectivamente, por:

$$0 \leq \alpha \leq 2^{QI} - 2^{QF}$$

$$-2^{QI-1} \leq \alpha \leq 2^{QI-1} - 2^{QF}$$

$$\epsilon = 2^{-QF}$$

Ainda, é importante definir o tamanho de dados em Q-format. Como QI e QF indicam a quantidade de bits disponíveis para representação do número, é simples que o tamanho é dado por:

$$WL = QI + QF$$

Vale ressaltar que podem haver diferentes formatos de representação Q-format com mesmo WL, e QI e QF distintos. Quanto maior QI, maior o range da representação, quanto maior QF, maior a resolução.

Passadas a caracterização geral de representação em Q-format, é interessante abordar a conversão de valores em ponto flutuante para ponto fixo e vice-versa. Para Q-format, o ponto é, de certa forma, virtual, já que na memória, o valor é guardado em um conjunto de bits de tamanho WL. Tome, como exemplo, Q2.6., unsigned. Os valores representados vão de  $0 \leq \alpha \leq 3.984375$ , com resolução  $\epsilon = 0.015625$ . Para passar um valor  $\alpha$  (cuja representação é feita em ponto flutuante), para ponto fixo, basta dividir o valor pela resolução  $\epsilon$  e aproximar para o inteiro mais próximo:

$$\alpha_{fixo} = \frac{\alpha_{flutuante}}{\epsilon}$$

Tomando  $\alpha_{flutuante} = 3.984375$ , temos que  $\alpha_{fixo} = 255$ . Em binário, 255 é representado por 11111111, ou seja, possui os 8 bits iguais a 1, correspondendo, corretamente, ao maior valor possível do formato. Esse processo de conversão faz sentido, pois divide o

número a ser armazenado pela resolução do Q-format adotado, ou seja, em passos inteiros do formato (por isso a aproximação após a divisão pela resolução).

A conversão de ponto fixo para ponto flutuante segue o caminho inverso: primeiro é necessário converter o valor armazenado em binário como um inteiro e multiplicar o resultado pela resolução  $\epsilon$ .

Em razão de se tratar de um formato mais rígido e com mais limitações de representação, o uso de Q-format implica em certa perda de precisão. Porém, a eficiência das implementações com Q-format é maior, em decorrência da facilidade de realizar operações matemáticas com os valores armazenados ([OBERSTAR, 2007](#)).



# REFERÊNCIAS

*Matrix*. Acessado em maio 2022. Disponível em: <https://i0.wp.com/www.deeplearningbook.com.br/wp-content/uploads/2018/01/matriz.png?resize=300%2C147ssl=1>>. Citado na página 2.

*Neurônio*. Acessado em maio 2022. Disponível em: <https://i1.wp.com/www.deeplearningbook.com.br/wp-content/uploads/2018/01/neuronio-matematico.png?w=543ssl=1>>. Citado na página 2.

*Neurônio*. Acessado em maio 2022. Disponível em: <https://i1.wp.com/www.deeplearningbook.com.br/wp-content/uploads/2018/01/neuronio.jpeg?resize=300%2C137ssl=1>>. Citado na página 3.

FRANCO, N. B. *Cálculo numérico*. [S.l.]: Pearson, 2006. Citado na página 5.

O Neurônio, Biológico e Matemático O Neurônio Matemático. Acessado em maio 2022. Disponível em: <https://www.deeplearningbook.com.br/o-neuronio-biologico-e-matematico/>>. Citado 3 vezes nas páginas 1, 2 e 3.

OBERSTAR, E. *Fixed-Point Representation and Fractional Math (revision 1.2)*. [S.l.]: August, Oberstar Consulting, online, available at <http://superkits.net> ..., 2007. Citado 2 vezes nas páginas 5 e 7.